AI on Chip 2024

LAB Ⅳ Processing Elements
REPORT

Student name: __胡家豪_____
Student ID: __N26122246_____

目錄

一.Implementation Result

1. TB.0

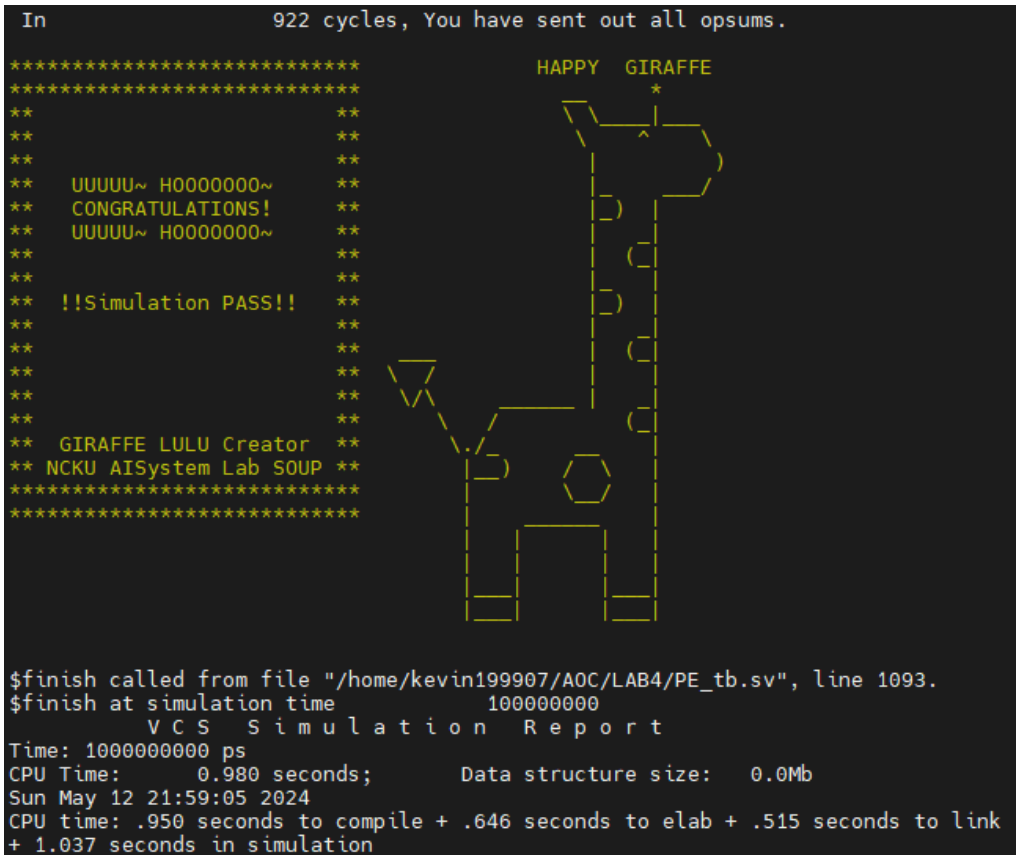

2. TB.1

3. TB.2

二. Implementation Cycle Result

Testbench	Tb0	Tb1	Tb2	Tb3
Clock Cycle	922	28163	8109	-

三. PE architecture and Design ideas

1. PE architecture

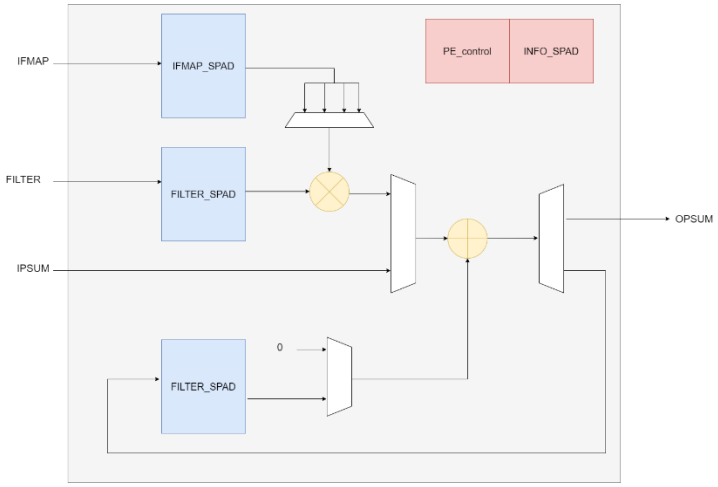

2. Spad storage space and functionality

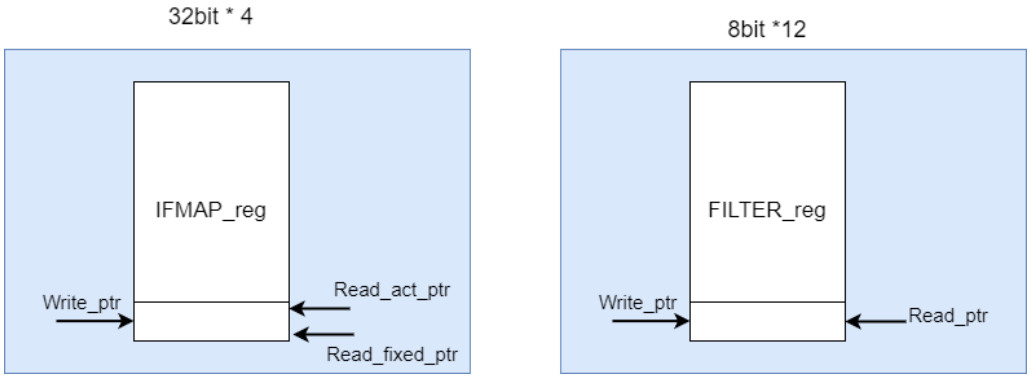

我使用的 spad 大小為 ifmap 的 16 Byte 與 Filter 的 12 Byte。

Ifmap 總共使用到三個 pointer 來進行讀寫，分別是 Write_pointer 負責資料寫入的地址、Read_fixed_pointer 負責固定 filter 框選到的大小與 Read_act_pointer 負責實際將資料讀出。
一開始 Write pointer 先寫入三筆資料，之後如果 sliding window 需要往右，就 write pointer 與 read fixed pointer 一起+1，然後 Read act pointer 會在 caculate 時對齊 Read fixed pointer 的位置，直到加到 Write pointer 的位置後告訴 control 完成運算

Filter 則只用到兩個 pointer，分別為 Write pointer 負責資料寫入的地址、Read pointer 負責資料讀取，每次計算完一次 convolution，Read pointer 就跳回原本的位置，直到要讀取新的 filter 進來。

3. FSM state and functionality

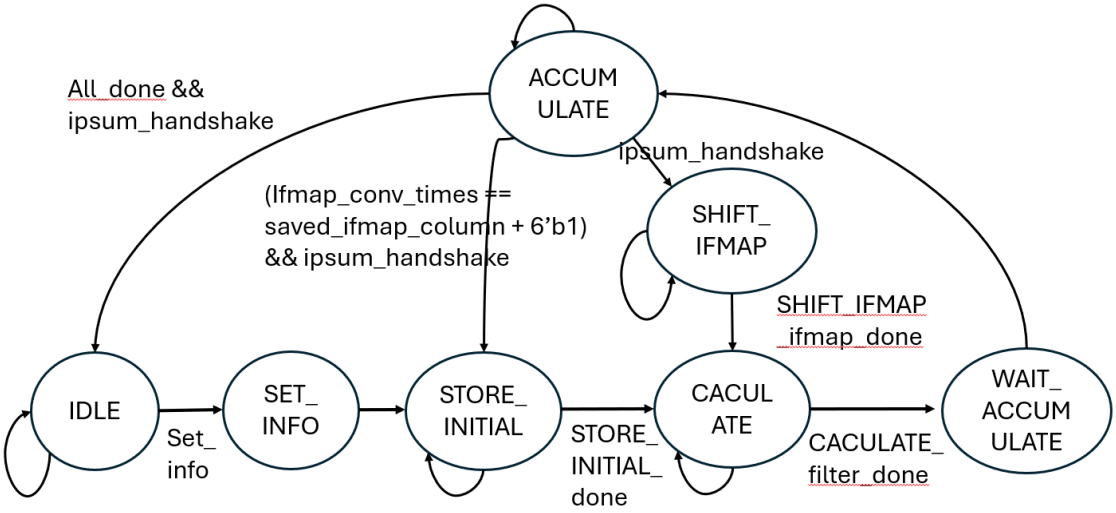

IDLE：閒置狀態

SET_INFO：吃到「set_info」後進入，此 stage 在儲存 Layer 的狀態。

STORE_INITIAL：存完 layer 後直接進入，在此狀態會將要儲存的 ifmap 以及 filter 讀入，之後每次要拿新的 ifmap 就會進入這個狀態重新拿取 ifmap 與 filter，並且會有 counter 計算要讀取幾個 ifmap 與 filter，都讀取後將 STORE_INITIAL_done 拉起

CACULATE：在這個 stage 會將 ifmap 與 filter 進行相乘相加，利用 counter 計算要相乘相加多少筆資料，完成後將 CACULATE_filter_done 拉起。

WAIT_ACCUMULATE：用於緩衝

ACCUMULATE：這邊將讀入的 ipsum 與算出來的結果相加乘 opsum，並把結果輸出。並且分為兩個情況。
情況 1：該次計算還沒有算完這個 ifmap，那就等待 ipsum Handshake 後將 ifmap 右移一格。
情況 2：該次計算已經算完這個 ifmap，那就等待 ipsum Handshake 後重新讀入 filter 與 ifmap。

SHIFT_IFMAP：這個狀態是一個 ifmap 還沒算完，所以進行右移，移完後就直接回到 CACULATE 進行下一次的運算。

4. Waveform Result

SET_INFO：

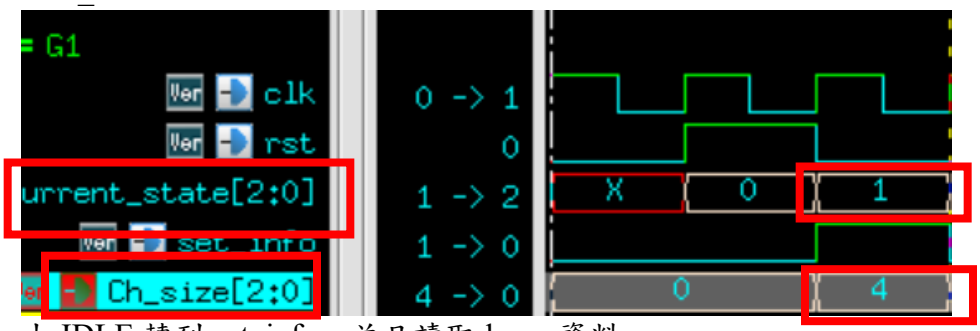

由 IDLE 轉到 set_info，並且讀取 layer 資料

STORE_INITIAL：

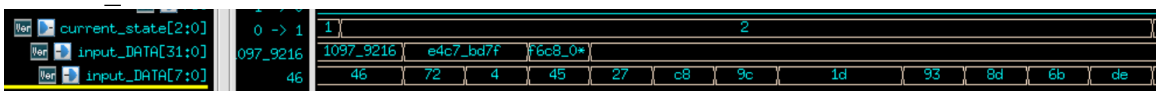

在這邊儲存四筆 ifmap 與 12 筆 filter (ch_size=4)

CACULATE：

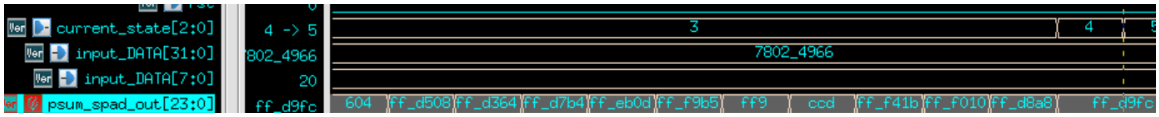

在這個階段進行 mac 運算並且存到 PSUM_SPAD 中

ACCUMULATE：

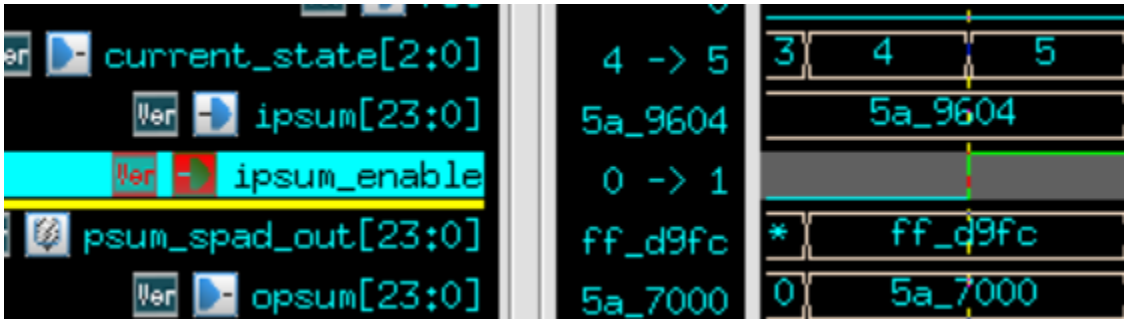

等待 Ipsum 將資料送進後，與 psum 相加後成為 opsum 送出。

SHIFT_MAP：

移動將 wrtie pointer 與 fix_read pointer 都加一，並且讓 act read pointer 與 fix read pointer 對齊。之後繼續進行 ACCUMULATE 的動作。

由於我使用的是 tb0，並沒有結束資訊的 wire，所以我計算我總共需要幾次 convolution 以及 ifmap_quant_size 的資訊來回到 IDLE，以 TB3 而言，總共進行 512 次

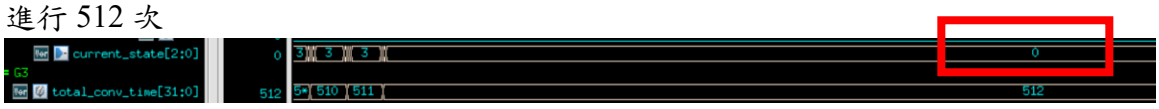

四.Demonstrate Scenario B dataflow

Demonstrate Scenario B dataflow by completing 2 **3row x 3col x 2ch ofmaps** by accumulating **2-channel of 2 3x3 ilters(kernel) and 2 5x5 ifmaps** under **parameters n=1, p=2(kernel), q=1(channel).**

N：一個 PE 一次執行幾個 ifmap
p：PE 執行一次有多少 kernal 存在 PE
q：一次算多少個 channel
Scenario B： ifmap reuse

根據上面的要求，我們可以將要進行的運算畫成如下所示，下面藍色為 ifmap、綠色為 kernal、黃色為 opsum 前三次運算會得到的部分。

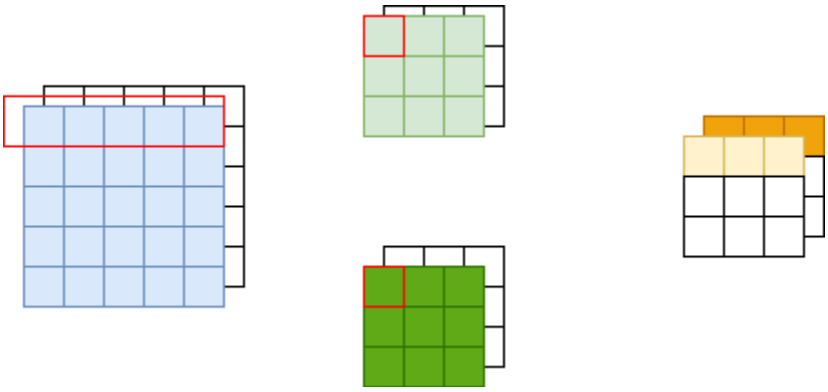

假設我們用 PE1,1 當作示例，ifmap 會直接存入 spad 之後在完成這個 row 之前都不再另外讀取其他的 data，而 filter 的 kernal 1 channel 1 與 kernal 2 channel 1 的一個元素則會由左至右不斷讀取進 PE 內進行運算，一次讀取兩個，在重複使用 ifmap 的情況下直接將兩個 kernal 完成運算，並且將輸出與其他的 PE 結果相加，完成一個 opsum，如下所示：

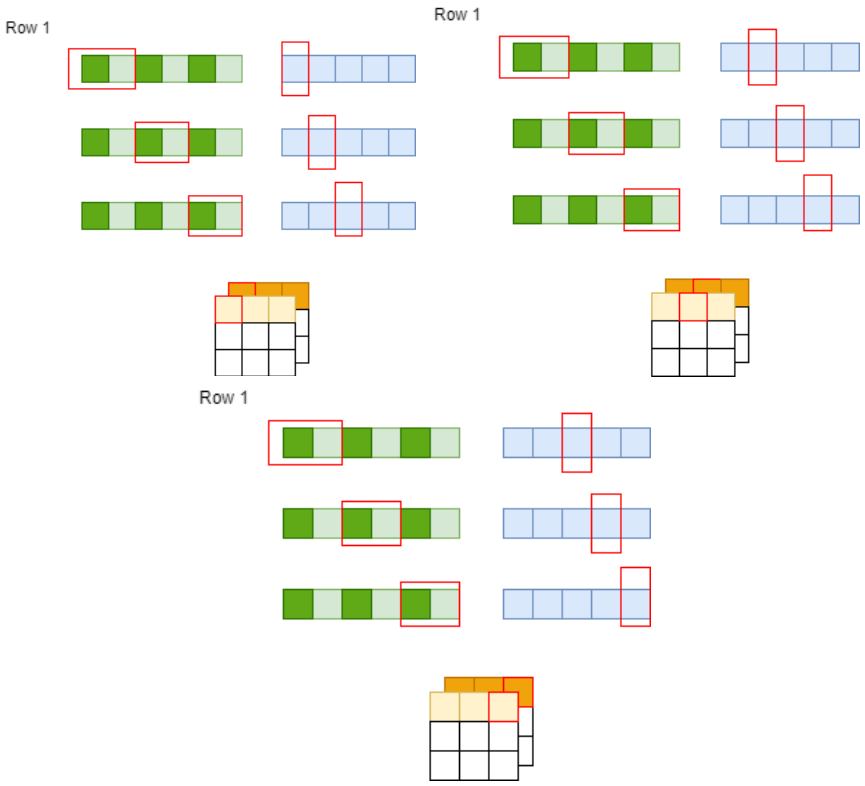

五. Compare scenario A,B,C from different aspects

	scenario A	scenario B	scenario C
Data reuse	Reuse filter，與不同的 ifmap 進行運算	Reuse ifmap，與不同的 filter(但相同 channel)進行運算	將不同 channel 但相同位置的部分同時運算，看要 reuse ifmap 或是 kernal
Spad size	Ifmap 每個 row 可能有較大 size 的 spad	Kernal 的 row 通常為 5 個或 3 個，較小 spad	中等
Memory R/W	較少	較多	中等
Energy comsumption	較小	較大	中等

六. Share your thoughts

本次作業比起前幾次作業而言來說規模比較大，也非常具有挑戰性。我覺得最難的部分在於理解作業要我們做甚麼。由於 Eyeriss 的架構比較複雜，而且又有許多 dataflow 的方式，所以光是看完助教的投影片與 youtube 影片就花了不少時間。

實作時我一開始打算使用 FIFO 當作 SPAD 的儲存，但是後來做出來在看波型時才發現 FIFO 會將 data 丟棄，而我們必須要將 data reuse，所以行不太通，浪費了不少時間才做出現在這個版本。

然而即便畫好 FSM，怎麼對 clock 也是一門學問，後面我常常在處理某些地方沒有考慮 handshake 的問題。

總體而言，雖然這次的作業相對困難，但是收獲也很大！